

## *Raport Tema 1 - Învățare Automată*

Nume: Vîrlan Mihnea-Alexandru

Grupa: 341C4

### **3.1. Analiza setului de date**

Cele 18 atribute ale pacienților din setul de date au prezentat o provocare, întrucât o parte considerabilă din acestea au prezentat anomalii, valori eronate, care dacă nu sunt tratate corect pot avea un impact negativ asupra performanțelor modelelor de învățare automată. În cele ce urmează, voi prezenta fiecare atribut într-o comparație before vs after. Comparația after apare numai acolo unde atributele au prezentat anomalii.


Observație: la corectarea anomaliilor din setul de date am decis să merg pe o strategie de imputare, desfășurată astfel:

1. Identificăm indecșii din setul de date unde un atribut prezintă valori anormale după inspectarea manuală. Vrem să obținem subsecvențe consecutive unde apar anomalii.
2. Dându-se o subsecvență de indecși cu anomalii, în care 2 indecși consecutivi au diferența 1 și sunt ordonați crescător, anomaliile vor fi înlocuite corespunzător pe baza datelor normale până la apariția anomaliilor.

De exemplu: dacă anomalii pentru un atribut A au fost semnalate la indecșii 300,301,302 și 400, pentru subsecvența 300,301,302 ne vom raporta la datele normale de la indecșii 0 până la 299 inclusiv, iar după ce acestea au fost tratate, vor fi folosite pentru a trata anomalia de la indicele 400 luând toate datele de la indicele 0 la 399 inclusiv.

- Transportation

Acest atribut indică preferințele pacienților în ceea ce privește modalitatea de transport. Fiindcă valorile posibile sunt Public\_Transportation, Bike, Wallking, Automobile și Motorbike am dedus că aceasta este o variabilă categorică, drept pentru care se poate face o histogramă.




Se poate observa că majoritatea pacienților ce se prezintă la clinică preferă transportul în comun (autobuze, troleibuze, tramvaie etc.), asociat cu lipsa efortului fizic, ceea ce duce în timp la probleme de sănătate.

Acest atribut nu a prezentat outlieri.


- Regular fiber\_diet

Intuitiv acest atribut ar trebui să indice care este nivelul de fibre prezent în hrana consumată de fiecare pacient, ceea ce înseamnă că atributul este discret fie sub forma: Scăzut, Mediu, Mare sau 1,2,3. Din nefericire observăm în setul de date că apar niște valori anormale. Fiind vorba despre un atribut categoric, virgulele din acele numere indică ordinul miilor, zecilor de mii etc. Inițial, o histogramă pe asemenea valori e imposibil de plotat și am decis să fac un pie chart.



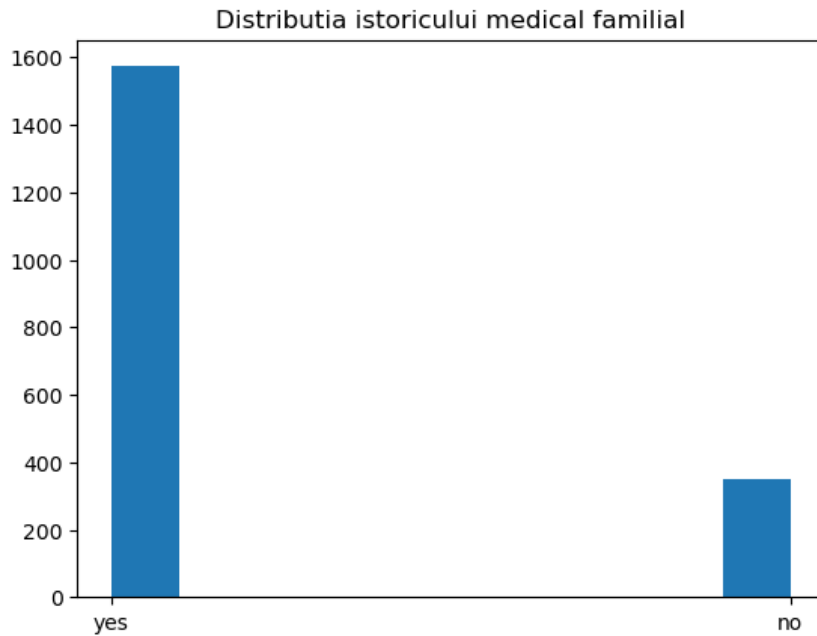
Se constată cu îngrijorare prezența semnificativă a valorilor anormale, cu un factor de alterare serios, ceea ce impune modificarea acestor atribute anormale.

Aplicăm transformarea datelor enunțată mai sus în care vom folosi pentru imputare clasa cea mai frecventă și obținem următorul pie-chart.



- Diagnostic\_in\_family\_history


S-a constatat că este o variabilă categorică binară, deci poate fi făcută o histogramă.



Se constată că prezența unui istoric medical în familia crește șansele prezentării la medic.

- High\_calorie\_diet

Este o variabilă categorică binară, deci se poate face o histogramă




Graficul arată astfel că, la nivelul setului de date pacienții care au meniuri bogate în calorii au șanse mai mari de a se prezenta la medic.

- Sedentary\_hours\_daily

Am observat că acest atribut numeric arată pentru fiecare pacient media numărului de ore în care nu face mișcare.

Am constatat un outlier, anume o valoare de 956.58 care apare doar o singură dată, deci putem șterge fără probleme înregistrarea respectivă din setul de date.

După eliminarea outlier-ului, să facem un boxplot



## Valorile statistice

```
count    1920.000000
mean      3.197276
std       0.575756
min       2.210000
25%       2.770000
50%       3.130000
75%       3.640000
max       4.670000
Name: Sedentary_hours_daily, dtype: float64
```

Valoarea IQR pentru acest atribut este 0.87, lucru care înseamnă că pentru 50% din aceste date, împrăștierea este una acceptabilă.

- Age

Acest atribut numeric prezintă, din păcate outlieri. După efectuarea unei sortări, analizând primele 100 de valori unice ale vârstelor am constatat niște valori nepermis de mari, pe care trebuie să le înlocuim. Vom folosi o imputare pe baza mediei după criteriul anunțat la început. Diferența cheie este că vom considera doar partea întreagă a acesteia.

```
In [53]: 1 sorted_by_age.index[:100]

Out[53]: Index([    15,    16,    17,    18,    19,    20,    21,    22,
    23,    24,    25,    26,    27,    28,    29,    30,
    31,    32,    33,    34,    35,    36,    37,    38,
    39,    40,    41,    44,    45,    51,    52,    55,
    56,    61,   19627,   19685,   176739,   203756,   209859,   210285,
   213928,   216548,   240409,   245822,   252984,   253292,   330816,   477061,
  1630687,  1638009,  1706713,  1708525,  1725813,  1770368,  1804892,  1810682,
  1813782,  1820634,  1848207,  1853084,  1883919,  1888061,  1888485,  1891505,
  1894093,  1916097,  1917614,  1921164,  1921638,  1947219,  1947554,  1959904,
  1972925,  1986997,  1988036,  1994814,  1996247,  1997166,  1997981,  2031094,
  2070768,  2081158,  2100829,  2101245,  2102064,  2102497,  2120563,  2128253,
  2167315,  2167447,  2172127,  2172738,  2181119,  2182165,  2190012,  2195994,
  2218881,  2239251,  2277789,  2287795],
              dtype='int32', name='Age')
```

Din nefericire un număr semnificativ de vârste sunt eronate

```
In [57]: 1 abnormal_ages=dataset[dataset["Age"]>61]
         2 abnormal_ages
```

```
Out[57]:
```

	Transportation	Regular_fiber_diet	Diagnostic_in_family_history	High_calorie_diet	Sedentary_hours_daily	Age	Alcohol	Est_avg_calorie_intak
457	Public_Transportation	3	yes	yes	3.14	25196214	Sometimes	165
458	Public_Transportation	3	yes	yes	3.81	18503343	Sometimes	215
460	Public_Transportation	3	yes	yes	3.17	21853826	Sometimes	262
461	Public_Transportation	3	yes	yes	2.39	2190012	Sometimes	155
462	Public_Transportation	3	yes	yes	3.64	18306615	Sometimes	173
...	...	...	...	...	...	...	...	...
1916	Public_Transportation	3	yes	yes	3.08	20976842	Sometimes	274
1917	Public_Transportation	3	yes	yes	3.00	21982942	Sometimes	297
1918	Public_Transportation	3	yes	yes	3.26	22524036	Sometimes	242
1919	Public_Transportation	3	yes	yes	3.61	24361936	Sometimes	237
1920	Public_Transportation	3	yes	yes	3.83	23664709	Sometimes	233

1252 rows x 9 columns


La final obținem următoarele statistici

```
In [44]: 1 dataset["Age"].describe()
```

```
Out[44]: count    1920.000000
         mean      22.489062
         std       3.651991
         min       15.000000
         25%       22.000000
         50%       22.000000
         75%       23.000000
         max       61.000000
         Name: Age, dtype: float64
```


Valoarea IQR este 1.

La final, facem un boxplot și constatăm că rămânem în continuare cu outliers, de data asta, având inclusiv vârste considerabil tinere (30,40 de ani). Acest lucru că o contaminare a unui atribut cu valori nepermis de mari duce la dezechilibre majore.



- Alcohol

Este o variabilă categorică având 4 valori posibile, deci se poate plota o histogramă.



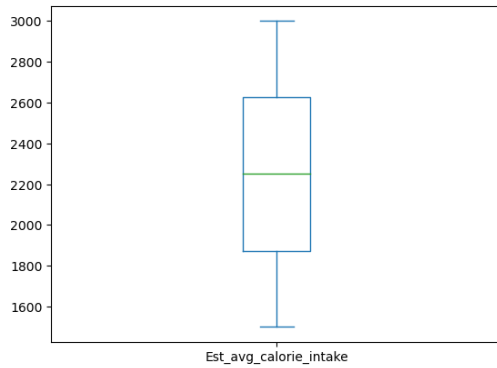
Vedem că majoritatea pacienților consumă ocazional alcool.

- Est\_avg\_calorie\_intake

Este un atribut numeric prin care vedem care este aportul caloric mediu al unui pacient. Nu s-au constatat valori anormale, deci putem face un boxplot.

```
count    1920.000000
mean     2253.405208
std       434.012263
min       1500.000000
25%      1870.250000
50%      2252.500000
75%      2628.000000
max       3000.000000
Name: Est_avg_calorie_intake, dtype: float64
```






Vedem că nu există outliers, deci putem presupune corectitudinea datelor acestui atribut. Valoarea IQR este 757.75, deci pentru 50% din pacienți avem o varietate considerabilă pentru acest atribut.

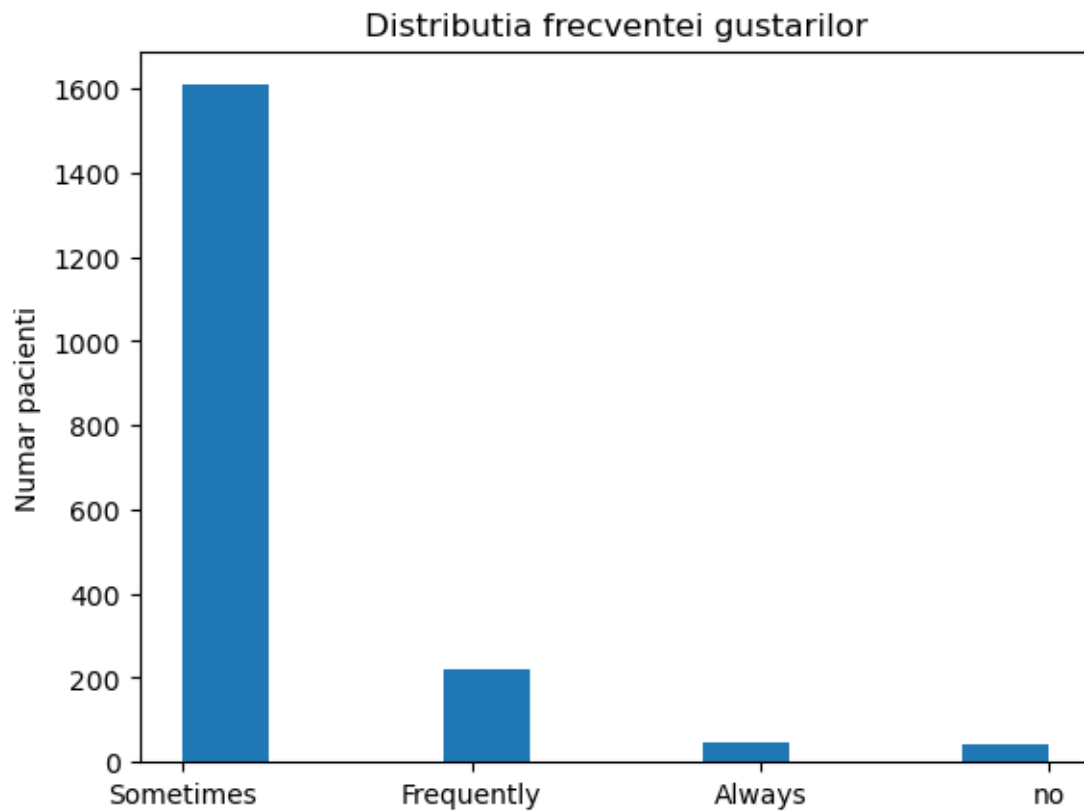
- Main\_meals\_daily

Este un atribut care arată pentru fiecare pacient, câte din cele 3 mese principale sunt servite. Aici, ar trebui să avem valori discrete foarte mici, dar setul de date este contaminat. Putem considera acest atribut ca fiind categoric. La final, obținem această histogramă.




- Snacks

Este o variabilă categorică, cu 4 valori posibile, deci putem face o histogramă.



- Height este un atribut numeric, număr real. În setul de date apar niște valori greșite pe care vrem să le corectăm.

După corecție avem acest boxplot



## Valori statistice


```
.]: 1 dataset["Height"].astype(float).describe()
```

```
.]: count    1920.000000  
   mean      1.702297  
   std       0.093224  
   min       1.450000  
   25%       1.630000  
   50%       1.700000  
   75%       1.770000  
   max       1.980000  
   Name: Height, dtype: float64
```

IQR este 0.14


- Smoker

Variabilă categorică binară, deci putem plota histograma




- Water\_daily

Ar trebui să fie un atribut categoric, care arată frecvența consumului de lichide. Avem inclusiv valori eronate. După corecție




- Calorie\_monitoring



Este o variabilă categorică binară, deci se poate plota o histogramă.

- Weight

Este un atribut numeric, care în setul de date conține și valori eronate care trebuie corectate. După un număr de iterații am ajuns la următorul boxplot




```
count    1920.000000
mean       86.582119
std       26.596913
min        39.000000
25%       66.739474
50%       82.015473
75%      105.984787
max      165.057269
Name: Weight, dtype: float64
```


IQR este 39.1

- Physical\_activity\_level


O variabilă categorică ce avusese valori eronate care au trebuit corectate, la final obținându-se histograma



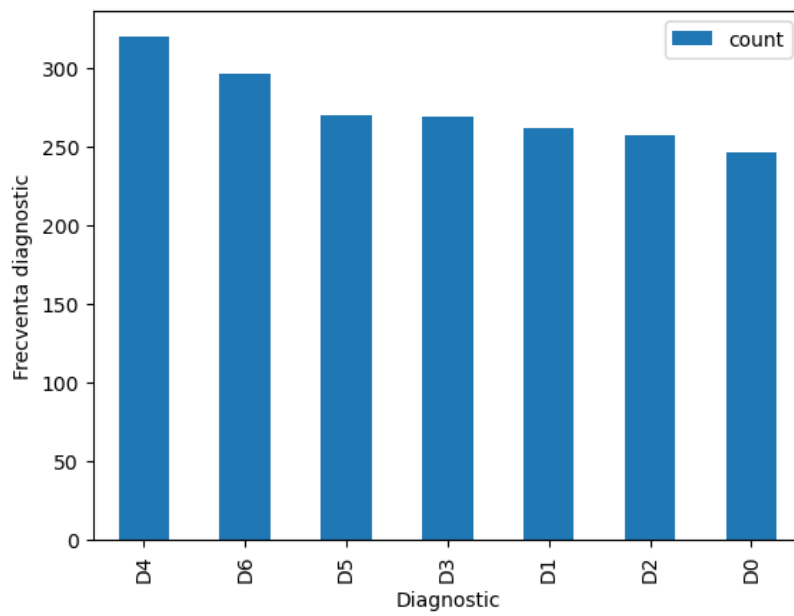
- Technology\_time\_use



- Gender




### Distribuția clasei diagnostic



Se constată din acest bar-plot că distribuția claselor este aproape echilibrată, ceea ce înseamnă că algoritmi de învățare automată nu vor favoriza o clasă în detrimentul alteia.

### Corelații între atribut și între atribut și clasă





Ca să ajung la diagrama corelației între atribute și între atribute și clasă, am transformat atributele care aveau valori sub formă de stringuri în numere folosind `OrdinalEncoder` din `scikit-learn`. Să analizăm diagrama.

- Vedem că diagnosticul este puternic afectat o serie de atribute, cele mai semnificative fiind `Weight` (o masă corporală mai mare crește posibilitatea unui anumit diagnostic) și prezența unui diagnostic în familie, din care deducem impactul genetic în stabilirea diagnosticului. Tot niște atribute semnificative în stabilirea diagnosticului sunt: prezența fibrelor în dietă și concentrația de calorii din dietă. Vedem însă și un rol al gustărilor și al nivelului de activitate fizică. Aparent un aport moderat de gustări ar reduce șansele unui anumit diagnostic. În mod firesc o activitate fizică redusă crește șansele unui diagnostic mai sever.
- Atributul `Weight` e în strânsă legătură cu istoricul medical de familie și cu înălțimea, ceea ce întărește ipoteza că masa corporală este factor cheie în stabilirea diagnosticului.
- Înălțimea e strâns legată de sexul pacientului, fiind foarte posibil ca pacienții de sex masculin să fie mai înalți decât pacienții de sex feminin.
- Atributele de folosirea tehnologiei și sedentarism sunt legate una de alta, dar niciuna dintre ele nu au un impact deosebit asupra diagnosticului

## 3.2 Feature Engineering și evaluarea de algoritmi

La etapa de feature engineering vom folosi `Variance Threshold`. `Variance Threshold` este o metodă de extragere de caracteristici în care sunt excluse atributele a căror varianță este sub un anumit prag. Acele varianțe excluse nu au o contribuție semnificativă în predicția atributului.

Vom explora în continuare ce atribute rămân dacă variem pragul.

- Pentru prag 0

```
In [313]: 1 variance_threshold=VarianceThreshold(threshold=0.0)
2 variance_threshold.fit(features,labels)
3 new_features=variance_threshold.get_support(indices=True)
4 new_dataset=dataset.iloc[:,new_features]
5 dataset.columns[new_features]
6 #new_dataset.to_numpy()
7 #train_val_features,test_features,train_val_y,test_y=train_test_split(new_dataset.to_numpy(),labels,
8 #random_state=42,test_size=0.2)

Out[313]: Index(['Transportation', 'Regular_fiber_diet', 'Diagnostic_in_family_history',
'High_calorie_diet', 'Sedentary_hours_daily', 'Age', 'Alcohol',
'Est_avg_calorie_intake', 'Main_meals_daily', 'Snacks', 'Height',
'Smoker', 'Water_daily', 'Calorie_monitoring', 'Weight',
'Physical_activity_level', 'Technology_time_use', 'Gender'],
dtype='object')
```

Vedem că toate atributele au o varianță nenulă

- Pentru prag 0.1

```
In [338]: 1 variance_threshold=VarianceThreshold(threshold=0.1)
2 variance_threshold.fit(features)
3 new_features_indexes=variance_threshold.get_support(indices=True)
4 new_dataset=dataset.iloc[:,new_features_indexes]
5 #print(dataset.columns[new_features_indexes])
6 all_features_indexes=np.arange(0,features.shape[1])
7 excluded_feature_indexes=np.array(list(set(all_features_indexes)-set(new_features_indexes)))
8 print("Excluded features",dataset.columns[excluded_feature_indexes])
9 print("Correlation of excluded features with the target variable")
10 for col in dataset.columns[excluded_feature_indexes]:
11     print("Corr between Diagnostic and {} is {}".format(col,dataset.corr()["Diagnostic"][col]))
12 #new_dataset.to_numpy()
13 #train_val_features,test_features,train_val_y,test_y=train_test_split(new_dataset.to_numpy(),labels,
14 #random_state=42,test_size=0.2)

Excluded features Index(['Height', 'Smoker', 'Calorie_monitoring'], dtype='object')
Correlation of excluded features with the target variable
Corr between Diagnostic and Height is 0.13019007655111536
Corr between Diagnostic and Smoker is -0.005093486025003062
Corr between Diagnostic and Calorie_monitoring is -0.18964450668598895
```

Observăm că s-a scos atributul smoker care aparent nu are o corelație puternică cu ținta, dar sunt scoase Calorie\_monitoring care pare să aibă o oarecare influență, dar și Height.

- Pragul de 0.2

```
2 labels=dataset.iloc[:,~1].to_numpy()

In [339]: 1 variance_threshold=VarianceThreshold(threshold=0.2)
2 variance_threshold.fit(features)
3 new_features_indexes=variance_threshold.get_support(indices=True)
4 new_dataset=dataset.iloc[:,new_features_indexes]
5 #print(dataset.columns[new_features_indexes])
6 all_features_indexes=np.arange(0,features.shape[1])
7 excluded_feature_indexes=np.array(list(set(all_features_indexes)-set(new_features_indexes)))
8 print("Excluded features",dataset.columns[excluded_feature_indexes])
9 print("Correlation of excluded features with the target variable")
10 for col in dataset.columns[excluded_feature_indexes]:
11     print("Corr between Diagnostic and {} is {}".format(col,dataset.corr()["Diagnostic"][col]))
12 #new_dataset.to_numpy()
13 #train_val_features,test_features,train_val_y,test_y=train_test_split(new_dataset.to_numpy(),labels,
14 #random_state=42,test_size=0.2)

Excluded features Index(['Diagnostic_in_family_history', 'High_calorie_diet', 'Height', 'Smoker',
'Water_daily', 'Calorie_monitoring'],
dtype='object')
Correlation of excluded features with the target variable
Corr between Diagnostic and Diagnostic_in_family_history is 0.5046920587060038
Corr between Diagnostic and High_calorie_diet is 0.24348928273131878
Corr between Diagnostic and Height is 0.13019007655111536
Corr between Diagnostic and Smoker is -0.005093486025003062
Corr between Diagnostic and Water_daily is 0.0704308834592036
Corr between Diagnostic and Calorie_monitoring is -0.18964450668598895
```

Vedem că la acest prag, attribute care influențează mai mult diagnosticul, precum `Diagnostic_in_family_history` și `High_calorie_diet` sunt excluse. E de menționat că atributul de diagnostic are o corelație de aproximativ 0.5 cu țina, iar pentru `High_calorie_diet` avem corelație de 0.24. De aici vedem că un atribut important este exclus.

- Pragul de 0.3

```
In [337]: 1 variance_threshold=VarianceThreshold(threshold=0.3)
2 variance_threshold.fit(features)
3 new_features_indexes=variance_threshold.get_support(indices=True)
4 new_dataset=dataset.iloc[:,new_features_indexes]
5 #print(dataset.columns[new_features_indexes])
6 all_features_indexes=np.arange(0,features.shape[1])
7 excluded_feature_indexes=np.array(list(set(all_features_indexes)-set(new_features_indexes)))
8 print("Excluded features",dataset.columns[excluded_feature_indexes])
9 print("Correlation of excluded features with the target variable")
10 for col in dataset.columns[excluded_feature_indexes]:
11     print("Corr between Diagnostic and {} is {}".format(col,dataset.corr()[["Diagnostic"]][col]))
12 #new_dataset.to_numpy()
13 #train_val_features,test_features,train_val_y,test_y=train_test_split(new_dataset.to_numpy(),Labels,
14                                     #random_state=42,test_size=0.2)

Excluded features Index(['Regular_fiber_diet', 'Diagnostic_in_family_history',
                        'High_calorie_diet', 'Alcohol', 'Snacks', 'Height', 'Smoker',
                        'Water_daily', 'Calorie_monitoring', 'Gender'],
                        dtype='object')
Correlation of excluded features with the target variable
Corr between Diagnostic and Regular_fiber_diet is 0.2494076964096828
Corr between Diagnostic and Diagnostic_in_family_history is 0.5046920587060038
Corr between Diagnostic and High_calorie_diet is 0.24348928273131878
Corr between Diagnostic and Alcohol is 0.14977667835302858
Corr between Diagnostic and Snacks is -0.3260519395456708
Corr between Diagnostic and Height is 0.13019007655111536
Corr between Diagnostic and Smoker is -0.005093486025003062
Corr between Diagnostic and Water_daily is 0.0704308834592036
Corr between Diagnostic and Calorie_monitoring is -0.18964450668598895
Corr between Diagnostic and Gender is -0.03651470293582483
```

Observăm de aici că încă un atribut important este, din păcate scos, aume `Regular_fiber_diet`. Un lucru interesant este la `Snacks`, căci în ciuda corelării negative, valoarea acesteia în modul nu poate fi neglijată.

Ținând cont de constatările făcute am decis că nu mai este cazul să creștem pragul, întrucât riscăm să eliminăm și alte attribute care ar putea influența predicția. Vom alege un prag sub 0.2 pentru a păstra attributele `Diagnostic_in_family` și `High_calorie_diet`.

Aleg drept prag valoarea de 0.1025, fiindcă doresc ca diagnosticul să fie influențat inclusiv de attribute considerate esențiale, printre care `Regular_fiber_diet`, `Diagnostic_in_family_history`, `High_calorie_diet`, `Snacks`, `Weight` și `Physical_activity_label`.

```

1 variance_threshold=VarianceThreshold(threshold=0.1025)
2 variance_threshold.fit(features)
3 new_features_indexes=variance_threshold.get_support(indices=True)
4 new_dataset=dataset.iloc[:,new_features_indexes]
5 #print(dataset.columns[new_features_indexes])
6 all_features_indexes=np.arange(0,features.shape[1])
7 excluded_feature_indexes=np.array(list(set(all_features_indexes)-set(new_features_indexes)))
8 print("Excluded features",dataset.columns[excluded_feature_indexes])
9 print("Correlation of excluded features with the target variable")
10 for col in dataset.columns[excluded_feature_indexes]:
11     print("Corr between Diagnostic and {} is {}".format(col,dataset.corr()["Diagnostic"][col]))
12 print("Considered columns for prediction: ",dataset.columns[new_features_indexes])
13 #new_dataset.to_numpy()
14 #train_val_features,test_features,train_val_y,test_y=train_test_split(new_dataset.to_numpy(),labels,
15                                     #random_state=42,test_size=0.2)

```

```

Excluded features Index(['Height', 'Smoker', 'Calorie_monitoring'], dtype='object')
Correlation of excluded features with the target variable
Corr between Diagnostic and Height is 0.13019007655111536
Corr between Diagnostic and Smoker is -0.005093486025003062
Corr between Diagnostic and Calorie_monitoring is -0.18964450668598895
Considered columns for prediction: Index(['Transportation', 'Regular_fiber_diet', 'Diagnostic_in_family_history',
    'High_calorie_diet', 'Sedentary_hours_daily', 'Age', 'Alcohol',
    'Est_avg_calorie_intake', 'Main_meals_daily', 'Snacks', 'Water_daily',
    'Weight', 'Physical_activity_level', 'Technology_time_use', 'Gender'],
    dtype='object')

```

În continuare, împărțim setul de date în setul de antrenare și validare, respectiv testare. 80% din date vor fi folosite pentru antrenare și validare, iar restul de 20% pentru testare.

Pentru că în noul set de date, după transformarea atributelor categorice sub formă de stringuri în numere, avem attribute categorice de o cifră, numere raționale la Sedentary\_hours\_daily și Weight, respectiv valori de ordinul miilor la Est\_avg\_calorie\_intake, considerăm că e necesară standardizarea datelor.

## Testarea algoritmilor

Conform documentației din scikit-learn, pentru o clasificare multi-clasă, pentru metricile f1, precision și recall voi folosi varianta macro, pentru că la acea variantă pentru fiecare clasă se iau metricile corespunzătoare și se împarte la numărul claselor.

- SVM

Variem parametrul C de regularizare între 0.1 și 1.4 inclusiv cu pas 0.1

Variem tipul kernelului între linear,rbf,sigmoid și poly

index	params	mean_test_accuracy	std_test_accuracy	mean_test_f1_macro	std_test_f1_macro	mean_test_recall_macro	std_test_recall_macro	mean_test_precision_macro	std_test_precision_macro
0	"{'C': 0.1, 'kernel': 'linear'}"	0.695327637	0.029655392	0.68390591	0.032501616	0.693294429	0.030357666	0.695191587	0.03362185
1	"{'C': 0.1, 'kernel': 'rbf'}"	0.620464064	0.021148039	0.596664381	0.022105908	0.61579248	0.021063566	0.65773513	0.030954597
2	"{'C': 0.1, 'kernel': 'poly'}"	0.476564152	0.020485413	0.442577223	0.020589312	0.456377378	0.020122839	0.622948995	0.067397035
3	"{'C': 0.1, 'kernel': 'sigmoid'}"	0.552749693	0.018781063	0.523108166	0.022351037	0.545805102	0.018722494	0.553722271	0.041579224
4	"{'C': 0.2, 'kernel': 'linear'}"	0.708993612	0.022869453	0.70097879	0.025177132	0.707543091	0.024023788	0.710018947	0.026382826
5	"{'C': 0.2, 'kernel': 'rbf'}"	0.648447481	0.021823562	0.635099125	0.025377407	0.645044197	0.02229566	0.656938151	0.025112856
6	"{'C': 0.2, 'kernel': 'poly'}"	0.576837007	0.022937287	0.572216252	0.020981323	0.566025331	0.023617533	0.681740881	0.024214176
7	"{'C': 0.2, 'kernel': 'sigmoid'}"	0.574882609	0.024534619	0.552298115	0.023396987	0.567604599	0.023525537	0.567037507	0.028775927
8	"{'C': 0.3000000000004, 'kernel': 'linear'}"	0.718103558	0.022561785	0.709323485	0.025615185	0.717038148	0.023477262	0.717466434	0.026741675
9	"{'C': 0.3000000000004, 'kernel': 'rbf'}"	0.68164474	0.022352767	0.675877323	0.023309066	0.680415392	0.022418472	0.690450631	0.024760958
10	"{'C': 0.3000000000004, 'kernel': 'poly'}"	0.595067473	0.015879781	0.590843386	0.014578385	0.58763157	0.015297631	0.66535575	0.013580193
11	"{'C': 0.3000000000004, 'kernel': 'sigmoid'}"	0.597662761	0.025835039	0.58072632	0.026792934	0.590841649	0.025675149	0.595269012	0.033528481
12	"{'C': 0.4, 'kernel': 'linear'}"	0.717454207	0.017781447	0.71095814	0.017752842	0.716407668	0.018868444	0.716710057	0.021207811

1 3	"{'C': 0.4, 'kernel': 'rbf'}"	0.70052 2442	0.0210 83201	0.69664 2298	0.0205 34023	0.700927 681	0.020804 938	0.70805798 9	0.0238473 62
1 4	"{'C': 0.4, 'kernel': 'poly'}"	0.61654 8923	0.0237 55621	0.61300 2011	0.0218 7433	0.609843 823	0.022881 772	0.66655530 1	0.0195823 51
1 5	"{'C': 0.4, 'kernel': 'sigmoid'} "	0.60090 5284	0.0239 07437	0.58487 2206	0.0244 46667	0.594252 866	0.023200 222	0.59723358 7	0.0324639 17
1 6	"{'C': 0.5, 'kernel': 'linear'}"	0.71940 4374	0.0224 655	0.71487 1639	0.0242 47648	0.718353 896	0.023518 027	0.7198093 7	0.0264002 32
1 7	"{'C': 0.5, 'kernel': 'rbf'}"	0.70703 0754	0.0198 70684	0.70310 0101	0.0196 71028	0.708020 985	0.019633 938	0.71084103 7	0.0208199 9
1 8	"{'C': 0.5, 'kernel': 'poly'}"	0.62630 6104	0.0179 14955	0.62369 7706	0.0162 56409	0.619800 309	0.017583 952	0.66945079 3	0.0159735 91
1 9	"{'C': 0.5, 'kernel': 'sigmoid'} "	0.59961 0813	0.0310 84016	0.58479 3457	0.0340 37801	0.591978 07	0.031037 888	0.59548846 7	0.0438356 25
2 0	"{'C': 0.6, 'kernel': 'linear'}"	0.72071 3651	0.0219 86228	0.71677 1623	0.0237 25611	0.720085 782	0.022651 843	0.72101715 6	0.0262168 9
2 1	"{'C': 0.6, 'kernel': 'rbf'}"	0.71223 402	0.0207 34767	0.70869 2689	0.0203 92735	0.713830 085	0.020367 478	0.71525480 5	0.0205577 12
2 2	"{'C': 0.6, 'kernel': 'poly'}"	0.64453 6571	0.0154 76216	0.64359 6301	0.0152 4736	0.639155 228	0.015482 695	0.68028847 7	0.0192103 49
2 3	"{'C': 0.6, 'kernel': 'sigmoid'} "	0.60221 4561	0.0250 74606	0.58945 3297	0.0294 77559	0.595068 819	0.025696 608	0.59750706 7	0.0343163 83
2 4	"{'C': 0.700000 0000000 001, 'kernel': 'linear'}"	0.72332 163	0.0213 04503	0.71930 3345	0.0224 64968	0.722636 184	0.021697 373	0.72407908 4	0.0252803 03
2 5	"{'C': 0.700000 0000000 001, 'kernel': 'rbf'}"	0.71939 1683	0.0240 73097	0.71622 0666	0.0236 07761	0.720900 626	0.024411 803	0.72277618 8	0.0224665 84
2 6	"{'C': 0.700000 0000000 001, 'kernel': 'poly'}"	0.65364 8631	0.0111 1091	0.65344 6731	0.0120 57037	0.648840 819	0.011700 993	0.68397958 8	0.0152375 29
2 7	"{'C': 0.700000 0000000 001, 'kernel': 'poly'}"	0.59830 9996	0.0228 49324	0.58473 8527	0.0263 43402	0.590845 724	0.023652 361	0.59233788 5	0.0311278 72

	'kernel': 'sigmoid'] "								
2 8	"{'C': 0.8, 'kernel': 'linear']"	0.72136 7232	0.0201 55893	0.71735 3207	0.0214 06624	0.720735 133	0.020740 73	0.72258131 9	0.0242371 44
2 9	"{'C': 0.8, 'kernel': 'rbf']"	0.72329 2017	0.0245 31678	0.72038 5485	0.0240 75854	0.724751 812	0.025236 235	0.72567265 9	0.0220719 9
3 0	"{'C': 0.8, 'kernel': 'poly']"	0.66211 7687	0.0141 19904	0.66083 5194	0.0145 41332	0.657557 043	0.015322 847	0.68829213 9	0.0150844 45
3 1	"{'C': 0.8, 'kernel': 'sigmoid'] "	0.59571 4709	0.0278 70496	0.58138 4579	0.0289 10648	0.588354 733	0.028337 245	0.58648663 1	0.0300060 67
3 2	"{'C': 0.9, 'kernel': 'linear']"	0.72136 3002	0.0202 21528	0.71771 9591	0.0213 66031	0.720906 539	0.020590 184	0.72262547 1	0.0237467 27
3 3	"{'C': 0.9, 'kernel': 'rbf']"	0.72654 5116	0.0227 54571	0.72422 487	0.0221 50687	0.727911 902	0.022868 223	0.72937210 8	0.0208601 05
3 4	"{'C': 0.9, 'kernel': 'poly']"	0.66602 8597	0.0154 6942	0.66394 4833	0.0163 59739	0.662013 728	0.016757 72	0.68642299 7	0.0159832 03
3 5	"{'C': 0.9, 'kernel': 'sigmoid'] "	0.58333 4743	0.0124 72012	0.56953 3234	0.0118 3885	0.576615 298	0.011703 259	0.57280098 7	0.0125141 64
3 6	"{'C': 1.0, 'kernel': 'linear']"	0.72201 4468	0.0202 15394	0.71819 1078	0.0212 73474	0.721587 53	0.020511 761	0.72254003 5	0.0237624 13
3 7	"{'C': 1.0, 'kernel': 'rbf']"	0.72784 8048	0.0239 80639	0.72611 0089	0.0236 77154	0.728999 002	0.024250 834	0.73138451	0.0228706 4
3 8	"{'C': 1.0, 'kernel': 'poly']"	0.66862 8115	0.0144 21093	0.66601 9872	0.0159 58883	0.664818 876	0.015778 879	0.68817630 8	0.0150693 46
3 9	"{'C': 1.0, 'kernel': 'sigmoid'] "	0.58463 3445	0.0185 31358	0.57126 3223	0.0181 82872	0.577718 587	0.018081 527	0.57466807 2	0.0200308 53
4 0	"{'C': 1.1, 'kernel': 'linear']"	0.72461 8216	0.0234 31222	0.72134 9567	0.0252 01466	0.724309 596	0.023774 241	0.72538248 2	0.0273245 2
4 1	"{'C': 1.1, 'kernel': 'rbf']"	0.73240 8308	0.0274 04513	0.73069 1466	0.0269 83979	0.733304 377	0.027183 572	0.73518834 1	0.0251322 8
4 2	"{'C': 1.1, 'kernel': 'poly']"	0.68099 5389	0.0150 06249	0.67823 0876	0.0159 61328	0.677313 63	0.015668 545	0.70081393 1	0.0150832
4 3	"{'C': 1.1, 'kernel': 'sigmoid'] "	0.57226 617	0.0198 04595	0.56114 5068	0.0189 50777	0.566561 509	0.019890 614	0.56307807 2	0.0205577 92
4 4	"{'C': 1.200000 0000000	0.72396 8865	0.0219 87784	0.72111 8982	0.0233 78276	0.723542 615	0.022419 822	0.72560656 8	0.0252000 39


	002, 'kernel': 'linear']"								
4 5	"{'C': 1.200000 0000000 002, 'kernel': 'rbf']"	0.73826 727	0.0254 1224	0.73652 8614	0.0250 44786	0.739077 427	0.025649 979	0.74142316 8	0.0234405 13
4 6	"{'C': 1.200000 0000000 002, 'kernel': 'poly']"	0.68685 6466	0.0159 85277	0.68426 6205	0.0165 15649	0.683492 01	0.015984 557	0.70482352 4	0.0177376 13
4 7	"{'C': 1.200000 0000000 002, 'kernel': 'sigmoid'] "	0.57487 6264	0.0150 25645	0.56270 3632	0.0142 95602	0.568529 321	0.015611 186	0.56522777 9	0.0148458 64
4 8	"{'C': 1.300000 0000000 003, 'kernel': 'linear']"	0.72462 0331	0.0216 12198	0.72155 0995	0.0234 07733	0.724236 894	0.022196 859	0.72578276 3	0.0253405 69
4 9	"{'C': 1.300000 0000000 003, 'kernel': 'rbf']"	0.73957 2317	0.0259 15016	0.73783 3638	0.0254 28125	0.740317 808	0.025943 882	0.74311732 5	0.0242794 7
5 0	"{'C': 1.300000 0000000 003, 'kernel': 'poly']"	0.69010 5334	0.0168 86605	0.68731 7023	0.0176 57082	0.686786 256	0.016798 396	0.70450953 7	0.0174744 25
5 1	"{'C': 1.300000 0000000 003, 'kernel': 'sigmoid'] "	0.56835 9491	0.0111 89645	0.55628 6489	0.0098 56841	0.562374 755	0.011220 528	0.55732591 3	0.0092016 18
5 2	"{'C': 1.400000 0000000 001, 'kernel': 'linear']"	0.72331 5284	0.0186 41208	0.71977 5028	0.0205 38	0.722814 248	0.019489 501	0.72357188	0.0218338 86
5 3	"{'C': 1.400000 0000000 001,	<b>0.74412 6232</b>	0.0272 65592	<b>0.74218 5964</b>	0.0267 31841	<b>0.744969 314</b>	0.027473 048	<b>0.74799916 6</b>	0.0259056 38



	'kernel': 'rbf']"								
5 4	"{'C': 1.400000 0000000 001, 'kernel': 'poly']"	0.69205 9732	0.0145 96686	0.68915 4054	0.0150 41967	0.688811 252	0.014296 219	0.70557108 9	0.0162905 51
5 5	"{'C': 1.400000 0000000 001, 'kernel': 'sigmoid'] "	0.55598 3756	0.0159 20292	0.54476 358	0.0125 04851	0.549989 249	0.014802 125	0.54669359 5	0.0111980 56

Observăm că un kernel care a jucat un rol central în obținerea celui mai bun rezultat este rbf. Faptul că a fost folosit RBF arată complexitatea atributelor, precum și neliniaritatea acestora, iar valoarea C de 1.4 arată că a fost necesară o valoare semnificativă pentru a reduce overfitting-ul rezultând o margine de separare mai mică și care să ducă la o clasificare mai bună. Parametrii au fost influențați de asemenea și de attribute care aveau o corelație mică cu clasa. Se poate observa din tabel că folosirea kernelului RBF duce la rezultate mai bune în comparație cu alte funcții kernel.

Pentru configurația de la linia 53 matricea de confuzie e următoarea



Din matricea de confuzie vedem că diagnosticul de indice 6 a obținut rezultate mai bune.

## Random Forest

index	params	mean_test_accuracy	std_test_accuracy	mean_test_f1_macro	std_test_f1_macro	mean_test_recall_macro	std_test_recall_macro	mean_test_precision_macro	std_test_precision_macro
0	"{'max_depth': 2, 'max_samples': 0.1, 'n_estimators': 10}"	0.503301747	0.045509531	0.447177023	0.058632422	0.493780861	0.048721151	0.510074137	0.097249271
1	"{'max_depth': 2, 'max_samples': 0.1, 'n_estimators': 60}"	0.618492745	0.0241802	0.586783629	0.026219811	0.614056451	0.022632181	0.630668726	0.034479705
2	"{'max_depth': 2, 'max_samples': 0.1, 'n_estimators': 100}"	0.617832819	0.016423124	0.581799672	0.018963043	0.61511521	0.016055	0.646967993	0.038702384

	'ples': 0.1, 'n_estima tors': 110}"								
3	"{'max_de pth': 2, 'max_sam ples': 0.1, 'n_estima tors': 160}"	0.61848 4284	0.0166 44561	0.582694 168	0.01695 6525	0.6150563 77	0.016150 073	0.65118309 5	0.0182255 72
4	"{'max_de pth': 2, 'max_sam ples': 0.1, 'n_estima tors': 210}"	0.61977 8755	0.0166 78315	0.580920 227	0.01723 1491	0.6174722 09	0.015497 856	0.64106869 4	0.0301765 33
5	"{'max_de pth': 2, 'max_sam ples': 0.1, 'n_estima tors': 260}"	0.62238 6734	0.0147 85179	0.581310 925	0.02020 7935	0.6197313 89	0.013844 649	0.64656213 5	0.0280975 94
6	"{'max_de pth': 2, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 10}"	0.56056 0937	0.0191 99765	0.520747 085	0.02403 9597	0.5505761 28	0.019552 808	0.57703739 6	0.0266120 63
7	"{'max_de pth': 2, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 60}"	0.61067 0925	0.0189 53667	0.578648 66	0.02073 7157	0.6072682 71	0.019222 172	0.65164724 4	0.0399535 18
8	"{'max_de pth': 2, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 110}"	0.61978 7216	0.0236 80387	0.584934 3	0.02672 6288	0.6169199 43	0.022809 259	0.68109708 6	0.0486384 53
9	"{'max_de pth': 2, 'max_sam ples': 0.300000	0.62238 4619	0.0218 85169	0.586788 222	0.02480 9233	0.6186174 49	0.022228 026	0.68462864 7	0.0484087 72

	00000000 004, 'n_estima tors': 160}"								
1 0	"{'max_de pth': 2, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 210}"	0.62628 7068	0.0198 49255	0.588671 151	0.02065 2665	0.6237372 08	0.019648 869	0.68291405 7	0.0447783 38
1 1	"{'max_de pth': 2, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 260}"	0.62890 3507	0.0088 41887	0.590946 204	0.00995 7911	0.6263973 98	0.007698 587	0.68293274 9	0.0346757 77
1 2	"{'max_de pth': 2, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 10}"	0.58139 3037	0.0205 87933	0.550360 035	0.02181 6675	0.5732431 46	0.021363 691	0.61366241 6	0.0521845 02
1 3	"{'max_de pth': 2, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 60}"	0.61523 1186	0.0181 84366	0.585345 014	0.01636 0341	0.6116905 03	0.016985 929	0.66201693 2	0.0472027 26
1 4	"{'max_de pth': 2, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 110}"	0.61262 7438	0.0174 12771	0.576007 027	0.01735 7961	0.6091179 72	0.015504 934	0.65793885 7	0.0419050 33
1 5	"{'max_de pth': 2, 'max_sam ples': 0.500000	0.61717 9238	0.0159 55894	0.579156 769	0.01600 6868	0.6142353 38	0.014494 852	0.66403106 2	0.0359929 3

	00000000 01, 'n_estima tors': 160}"								
1 6	"{'max_de pth': 2, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 210}"	0.61912 9405	0.0219 83576	0.579453 477	0.02330 6061	0.6163649 14	0.020971 428	0.66647936 2	0.0464880 82
1 7	"{'max_de pth': 2, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 260}"	0.62499 4712	0.0099 35865	0.584065 718	0.01233 4042	0.6227786 21	0.009438 307	0.66853228 9	0.0436787 99
1 8	"{'max_de pth': 2, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 10}"	0.57486 7803	0.0258 89066	0.534356 95	0.03009 013	0.5666215 29	0.028332 754	0.61277321 9	0.0532281 42
1 9	"{'max_de pth': 2, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 60}"	0.61458 1835	0.0186 33739	0.584822 366	0.01818 9713	0.6097384 77	0.017893 976	0.65149196 1	0.0371300 88
2 0	"{'max_de pth': 2, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 110}"	0.62109 4378	0.0178 92173	0.588798 836	0.02007 6308	0.6176211 46	0.016873 994	0.67963107 1	0.0435483 59
2 1	"{'max_de pth': 2, 'max_sam ples': 0.700000	0.61588 6882	0.0176 82628	0.580457 524	0.01889 518	0.6120348 52	0.017195 453	0.66711361 8	0.0404978 47

	00000000 01, 'n_estima tors': 160}"								
2 2	"{'max_de pth': 2, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 210}"	0.62043 6567	0.0142 15864	0.582869 387	0.01304 7037	0.6173549 67	0.012987 829	0.67255596 4	0.0432774 85
2 3	"{'max_de pth': 2, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 260}"	0.62629 7644	0.0074 60416	0.587986 836	0.00934 2663	0.6239817 57	0.006595 923	0.67710962 1	0.0386431 36
2 4	"{'max_de pth': 2, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 10}"	0.58334 7434	0.0218 03059	0.547572 589	0.02481 296	0.5751499 02	0.023029 396	0.61758008 9	0.0458118 2
2 5	"{'max_de pth': 2, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 60}"	0.60806 9292	0.0183 33944	0.574121 422	0.01879 333	0.6033832 63	0.017599 197	0.65083389 7	0.0333460 42
2 6	"{'max_de pth': 2, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 110}"	0.61783 4934	0.0235 95657	0.582493 86	0.02853 1046	0.6138285 37	0.023027 619	0.66306429 3	0.0427514 95
2 7	"{'max_de pth': 2, 'max_sam ples': 0.900000	0.62043 6567	0.0164 31555	0.586365 357	0.01714 582	0.6159879 82	0.017104 856	0.67586221 5	0.0219520 34

	00000000 01, 'n_estima tors': 160}"								
2 8	"{'max_de pth': 2, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 210}"	0.62499 6827	0.0123 43335	0.588055 162	0.01305 6528	0.6221920 31	0.011315 746	0.68136509 1	0.0324058 88
2 9	"{'max_de pth': 2, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 260}"	0.62825 2041	0.0079 50579	0.590407 395	0.01449 5837	0.6261303 53	0.008226 997	0.67819695 7	0.0379881 23
3 0	"{'max_de pth': 3, 'max_sam ples': 0.1, 'n_estima tors': 10}"	0.56707 7711	0.0282 80172	0.540279 636	0.02623 7386	0.5631604 67	0.029262 938	0.57535347 8	0.0473263 57
3 1	"{'max_de pth': 3, 'max_sam ples': 0.1, 'n_estima tors': 60}"	0.66408 0545	0.0191 32797	0.644896 298	0.01892 83	0.6629542 85	0.017561 014	0.66606113 4	0.0139775 77
3 2	"{'max_de pth': 3, 'max_sam ples': 0.1, 'n_estima tors': 110}"	0.67124 0323	0.0172 63097	0.652269 496	0.01761 2747	0.6708746 73	0.016785 955	0.67772353 4	0.0201522 84
3 3	"{'max_de pth': 3, 'max_sam ples': 0.1, 'n_estima tors': 160}"	0.67644 9934	0.0211 735	0.658494 717	0.02254 6208	0.6761906 95	0.020049 593	0.68136402 9	0.0253091 1
3 4	"{'max_de pth': 3, 'max_sam ples': 0.1, 'n_estima tors': 210}"	0.67383 5611	0.0120 41106	0.654064 745	0.01236 2769	0.6734733 13	0.010692 838	0.68133115 4	0.0107147 32

35	"{'max_depth': 3, 'max_samples': 0.1, 'n_estimators': 260}"	0.679694573	0.015615033	0.659148653	0.019868372	0.680241612	0.015114668	0.687275771	0.019089303
36	"{'max_depth': 3, 'max_samples': 0.300000000000000004, 'n_estimators': 10}"	0.629561318	0.015502719	0.60633802	0.015837662	0.626083166	0.01143688	0.623303135	0.016609325
37	"{'max_depth': 3, 'max_samples': 0.300000000000000004, 'n_estimators': 60}"	0.689491941	0.031159575	0.671521701	0.037164991	0.689739643	0.031435327	0.693504792	0.034788496
38	"{'max_depth': 3, 'max_samples': 0.300000000000000004, 'n_estimators': 110}"	0.672539024	0.016013991	0.651612154	0.018565672	0.672750468	0.015153185	0.684151821	0.023348684
39	"{'max_depth': 3, 'max_samples': 0.300000000000000004, 'n_estimators': 160}"	0.679694573	0.01373522	0.660073091	0.014430787	0.67986105	0.013191727	0.694035312	0.018759963
40	"{'max_depth': 3, 'max_samples': 0.300000000000000004, 'n_estimators': 210}"	0.680995389	0.015561614	0.659965674	0.018175656	0.681374317	0.015373479	0.694066291	0.017310644
41	"{'max_depth': 3, 'max_sam	0.684902069	0.014625836	0.665717641	0.017598124	0.685238178	0.014630949	0.694417364	0.018625035



	ples': 0.300000 00000000 004, 'n_estima tors': 260}"								
4 2	"{'max_de pth': 3, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 10}"	0.63411 1003	0.0242 14599	0.612625 063	0.02346 9618	0.6307706 55	0.021480 896	0.62649214 4	0.0248816 51
4 3	"{'max_de pth': 3, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 60}"	0.68816 7858	0.0259 50654	0.672686 122	0.02477 6925	0.6877903 82	0.024224 421	0.68901597 8	0.0274546 91
4 4	"{'max_de pth': 3, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 110}"	0.67773 806	0.0229 76264	0.655364 934	0.02530 1439	0.6783734 41	0.021519 756	0.68779890 7	0.0255058 35
4 5	"{'max_de pth': 3, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 160}"	0.69075 68	0.0145 2742	0.672778 398	0.01340 3788	0.6912189 78	0.013279 558	0.69851248 2	0.0153151 55
4 6	"{'max_de pth': 3, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 210}"	0.68229 409	0.0211 29129	0.661704 789	0.02223 4292	0.6828247 04	0.020476 346	0.69101965 2	0.0231191 09
4 7	"{'max_de pth': 3, 'max_sam	0.69076 3146	0.0169 57595	0.672553 332	0.01847 325	0.6918698 35	0.016370 921	0.70018219 4	0.0197729 97

	ples': 0.500000 00000000 01, 'n_estima tors': 260}"								
4 8	"{'max_de pth': 3, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 10}"	0.63020 4323	0.0151 71562	0.608133 743	0.01253 2568	0.6272511 07	0.012129 224	0.61649168 5	0.0149491 16
4 9	"{'max_de pth': 3, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 60}"	0.68946 0214	0.0156 19452	0.674439 062	0.01460 3107	0.6887860 94	0.014031 561	0.68793303 9	0.0180199 78
5 0	"{'max_de pth': 3, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 110}"	0.68685 4351	0.0161 61254	0.668175 711	0.01757 2697	0.6868973 26	0.014806 503	0.68628674 1	0.0208549 65
5 1	"{'max_de pth': 3, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 160}"	0.69141 0381	0.0152 43021	0.673570 226	0.01363 4979	0.6913695 8	0.014107 838	0.69369094 1	0.0149107 99
5 2	"{'max_de pth': 3, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 210}"	0.68034 3923	0.0161 59088	0.659495 345	0.01870 9688	0.6807794 47	0.015662 412	0.68589820 9	0.0223468 76
5 3	"{'max_de pth': 3, 'max_sam	0.68881 2979	0.0198 53385	0.670594 034	0.02326 5675	0.6899098 19	0.019486 051	0.69771513 3	0.0254783 95

	ples': 0.700000 00000000 01, 'n_estima tors': 260}"								
5 4	"{'max_de pth': 3, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 10}"	0.62436 6513	0.0186 78161	0.597874 173	0.02562 0481	0.6197785 65	0.016780 485	0.60920068 6	0.0282670 31
5 5	"{'max_de pth': 3, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 60}"	0.68230 8896	0.0204 72666	0.665868 793	0.02163 0823	0.6815643 09	0.019770 814	0.67870452 6	0.0266812 49
5 6	"{'max_de pth': 3, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 110}"	0.68425 6948	0.0172 40872	0.667402 474	0.01820 5515	0.6843094 41	0.015787 561	0.68590349 4	0.0219340 93
5 7	"{'max_de pth': 3, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 160}"	0.69400 9899	0.0192 19594	0.676141 648	0.02053 6279	0.6943989 97	0.018320 768	0.69533096	0.0195666 25
5 8	"{'max_de pth': 3, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 210}"	0.69011 168	0.0213 31889	0.670612 666	0.02431 1132	0.6907118 63	0.020235 358	0.69928267 5	0.0260981 12
5 9	"{'max_de pth': 3, 'max_sam	0.69728 4149	0.0201 91588	0.680859 068	0.02298 0479	0.6982742 15	0.018936 352	0.70110464 8	0.0224990 85

	ples': 0.900000 00000000 01, 'n_estima tors': 260}"								
6 0	"{'max_de pth': 4, 'max_sam ples': 0.1, 'n_estima tors': 10}"	0.61135 2003	0.0363 73652	0.590033 626	0.03758 9394	0.6097995 85	0.039223 387	0.62185755 3	0.0411197 95
6 1	"{'max_de pth': 4, 'max_sam ples': 0.1, 'n_estima tors': 60}"	0.69921 105	0.0128 01902	0.688792 249	0.01280 8356	0.7003723 49	0.011427 475	0.70238107 1	0.0139028 89
6 2	"{'max_de pth': 4, 'max_sam ples': 0.1, 'n_estima tors': 110}"	0.70637 9288	0.0191 59364	0.694578 176	0.02019 7563	0.7083688 33	0.017807 313	0.70719463 2	0.0234021 97
6 3	"{'max_de pth': 4, 'max_sam ples': 0.1, 'n_estima tors': 160}"	0.72200 8122	0.0193 4535	0.712597 846	0.02053 3114	0.7244867 87	0.018665 196	0.72223118 4	0.0224784 17
6 4	"{'max_de pth': 4, 'max_sam ples': 0.1, 'n_estima tors': 210}"	0.71940 4374	0.0211 01697	0.709515 156	0.02167 7501	0.7213284 29	0.020175 725	0.71926386 8	0.0251524 04
6 5	"{'max_de pth': 4, 'max_sam ples': 0.1, 'n_estima tors': 260}"	0.71419 4763	0.0178 51428	0.703081 459	0.01909 2092	0.7160914 98	0.017292 276	0.71520975 4	0.0212629 46
6 6	"{'max_de pth': 4, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 10}"	0.63675 2824	0.0320 38178	0.613932 645	0.03654 5938	0.6352044 34	0.034352 765	0.64281390 3	0.0426594 25
6 7	"{'max_de pth': 4, 'max_sam ples': 0.1, 'n_estima tors': 10}"	0.71812 0479	0.0292 33641	0.707155 968	0.03371 1149	0.7193103 94	0.029355 338	0.72019268 8	0.0333413 56

	'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 60}"								
6 8	"{'max_de pth': 4, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 110}"	0.72136 0887	0.0290 36009	0.709615 346	0.03158 1373	0.7222125 8	0.028874 795	0.72304688 7	0.0367383 84
6 9	"{'max_de pth': 4, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 160}"	0.72722 1964	0.0155 85242	0.716846 163	0.01444 0294	0.7285279 06	0.0153	0.72960342 7	0.0183007 91
7 0	"{'max_de pth': 4, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 210}"	0.72917 2131	0.0132 95229	0.719067 106	0.01180 8651	0.7307396 67	0.013295 078	0.73080690 4	0.0143299 4
7 1	"{'max_de pth': 4, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 260}"	0.73243 369	0.0187 43149	0.723222 531	0.01879 6148	0.7343473 24	0.018453 43	0.73451541 2	0.0227181 46
7 2	"{'max_de pth': 4, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 10}"	0.64389 1451	0.0273 74346	0.615669 069	0.03076 129	0.6422495 58	0.027186 175	0.63236809 7	0.0291894 56
7 3	"{'max_de pth': 4, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 10}"	0.71746 0552	0.0337 61041	0.705524 365	0.03710 7728	0.7184444 5	0.033437 871	0.71897519	0.0383979 08

	'max_samples': 0.5000000000000001, 'n_estimators': 60}"								
74	"{'max_depth': 4, 'max_samples': 0.5000000000000001, 'n_estimators': 110}"	0.726564152	0.030400112	0.716548762	0.033392772	0.72752188	0.030000655	0.731096026	0.034812941
75	"{'max_depth': 4, 'max_samples': 0.5000000000000001, 'n_estimators': 160}"	0.732423114	0.025499994	0.723648197	0.026188595	0.733465373	0.024925477	0.736326522	0.027768331
76	"{'max_depth': 4, 'max_samples': 0.5000000000000001, 'n_estimators': 210}"	0.734375397	0.026101094	0.726018721	0.027458651	0.735522269	0.025723766	0.737411879	0.028125822
77	"{'max_depth': 4, 'max_samples': 0.5000000000000001, 'n_estimators': 260}"	0.738939887	0.028943958	0.730545955	0.030743431	0.7404544	0.028753649	0.741405349	0.032240557
78	"{'max_depth': 4, 'max_samples': 0.7000000000000001, 'n_estimators': 10}"	0.639989001	0.016966106	0.613181987	0.023699065	0.639281481	0.017065928	0.638858822	0.033237927
79	"{'max_depth': 4, 'n_estimators': 10}"	0.721365117	0.024116509	0.712415548	0.025014084	0.72244845	0.023469666	0.720174516	0.024335738

	'max_samples': 0.7000000000000001, 'n_estimators': 60}"								
80	"{'max_depth': 4, 'max_samples': 0.7000000000000001, 'n_estimators': 110}"	0.724620331	0.026144503	0.715490937	0.028139674	0.725606362	0.025032949	0.725215761	0.026535088
81	"{'max_depth': 4, 'max_samples': 0.7000000000000001, 'n_estimators': 160}"	0.72787766	0.023286055	0.718289885	0.024638308	0.729067091	0.022556494	0.728030634	0.024175601
82	"{'max_depth': 4, 'max_samples': 0.7000000000000001, 'n_estimators': 210}"	0.73242946	0.022031697	0.724294235	0.020995022	0.733763774	0.020725428	0.733459024	0.019822717
83	"{'max_depth': 4, 'max_samples': 0.7000000000000001, 'n_estimators': 260}"	0.730477178	0.019999634	0.721385731	0.019529404	0.732139837	0.018698895	0.729861149	0.020798324
84	"{'max_depth': 4, 'max_samples': 0.9000000000000001, 'n_estimators': 10}"	0.649107407	0.039891997	0.631785317	0.041606172	0.647416701	0.038773997	0.653944707	0.037125372
85	"{'max_depth': 4,	0.719404374	0.020176346	0.711181191	0.020621548	0.719791409	0.020121587	0.721492481	0.018306637

	'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 60}"								
8 6	"{'max_de pth': 4, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 110}"	0.73698 972	0.0221 8614	0.729443 579	0.02322 0826	0.7376190 45	0.021463 993	0.73876745 6	0.0222320 89
8 7	"{'max_de pth': 4, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 160}"	0.74089 8515	0.0216 89426	0.733767 021	0.02258 5363	0.7418767 7	0.020960 206	0.74097748 6	0.0223640 99
8 8	"{'max_de pth': 4, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 210}"	0.74545 8776	0.0263 22223	0.738439 381	0.02656 8496	0.7466347 78	0.025642 935	0.74680198 4	0.0259207 56
8 9	"{'max_de pth': 4, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 260}"	0.74285 0797	0.0199 0701	0.735998 404	0.02059 3077	0.7443792 66	0.019196 142	0.74471683 7	0.0204985 41
9 0	"{'max_de pth': 5, 'max_sam ples': 0.1, 'n_estima tors': 10}"	0.63867 3379	0.0210 78644	0.621037 271	0.02615 0419	0.6386876 24	0.021713 945	0.64567598 9	0.0211772 68
9 1	"{'max_de pth': 5, 'max_sam ples': 0.1,	0.72461 6101	0.0246 06203	0.716955 639	0.02400 9488	0.7265205 53	0.023961 057	0.72649021 8	0.0251357 18



	'n_estimators': 60}"								
9 2	"{'max_de pth': 5, 'max_sam ples': 0.1, 'n_estima tors': 110}"	0.73633 8255	0.0190 64151	0.729371 96	0.01790 5987	0.7374130 74	0.018310 299	0.73659904 7	0.0221608 25
9 3	"{'max_de pth': 5, 'max_sam ples': 0.1, 'n_estima tors': 160}"	0.73764 3301	0.0236 53154	0.731248 746	0.02289 123	0.7386570 67	0.023453 511	0.73690545 2	0.0246557 99
9 4	"{'max_de pth': 5, 'max_sam ples': 0.1, 'n_estima tors': 210}"	0.74350 4378	0.0302 36773	0.736921 617	0.02940 4785	0.7449103 17	0.029960 867	0.74260831 2	0.0324159 79
9 5	"{'max_de pth': 5, 'max_sam ples': 0.1, 'n_estima tors': 260}"	0.74414 9499	0.0291 66709	0.737658 343	0.02877 4834	0.7455897 54	0.029203 291	0.74269787 3	0.0304898 8
9 6	"{'max_de pth': 5, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 10}"	0.68817 6319	0.0238 62798	0.676318 954	0.02421 4363	0.6878150 9	0.025981 952	0.68614975	0.0213346 5
9 7	"{'max_de pth': 5, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 60}"	0.75261 4324	0.0201 54706	0.747296 937	0.02051 1273	0.7533596 75	0.019837 56	0.75523524 7	0.0174417 69
9 8	"{'max_de pth': 5, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 110}"	0.76434 0708	0.0222 23099	0.759581 385	0.02181 1247	0.7653452 16	0.021717 449	0.76712086	0.0231163 5

99	"{'max_depth': 5, 'max_samples': 0.3000000000000004, 'n_estimators': 160}"	0.763033546	0.018636483	0.758111266	0.017680563	0.764053807	0.017916348	0.764347592	0.019449943
100	"{'max_depth': 5, 'max_samples': 0.3000000000000004, 'n_estimators': 210}"	0.76238208	0.020130963	0.757148029	0.020056243	0.763408094	0.019530765	0.763471343	0.021669298
101	"{'max_depth': 5, 'max_samples': 0.3000000000000004, 'n_estimators': 260}"	0.761734845	0.023792006	0.756963164	0.023257892	0.762889262	0.023073639	0.76271275	0.025064578
102	"{'max_depth': 5, 'max_samples': 0.5000000000000001, 'n_estimators': 10}"	0.701178138	0.029600576	0.690774003	0.032480851	0.701019248	0.02863733	0.699988512	0.029424944
103	"{'max_depth': 5, 'max_samples': 0.5000000000000001, 'n_estimators': 60}"	0.765645755	0.027820413	0.76064488	0.027678824	0.766516727	0.028522471	0.76720801	0.028880512
104	"{'max_depth': 5, 'max_samples': 0.5000000000000001, 'n_estimators': 110}"	0.764990059	0.025763888	0.760212103	0.025319504	0.765947627	0.025519194	0.769055744	0.025458214

1 0 5	"{'max_de pth': 5, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 160}"	0.77150 2602	0.0286 32583	0.767169 947	0.02908 5439	0.7722779 83	0.028538 898	0.77471980 2	0.0305616 82
1 0 6	"{'max_de pth': 5, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 210}"	0.77670 3752	0.0246 63439	0.772763 83	0.02448 1217	0.7774718 1	0.024505 461	0.78099737	0.0251227 58
1 0 7	"{'max_de pth': 5, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 260}"	0.77150 0486	0.0250 15806	0.767432 65	0.02569 8996	0.7722940 62	0.024904 209	0.77508003 4	0.0276599 69
1 0 8	"{'max_de pth': 5, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 10}"	0.71419 4763	0.0277 99096	0.700575 71	0.02919 262	0.7151249 24	0.028304 836	0.71119618 4	0.0310502 02
1 0 9	"{'max_de pth': 5, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 60}"	0.76434 2823	0.0268 66351	0.759493 175	0.02714 922	0.7653797 12	0.027448 107	0.76724357 4	0.0282578 04
1 1 0	"{'max_de pth': 5, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 110}"	0.77019 1209	0.0197 11797	0.766321 953	0.01816 6582	0.7716002 47	0.019266 865	0.77513819 3	0.0195766 72

1 1 1	"{'max_de pth': 5, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 160}"	0.76954 1859	0.0172 53545	0.765053 812	0.01698 9621	0.7706282 62	0.017170 579	0.77219540 5	0.0188158 68
1 1 2	"{'max_de pth': 5, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 210}"	0.77279 7073	0.0216 22138	0.768532 319	0.02119 4359	0.7740427 94	0.021467 994	0.77551766 9	0.0230102 05
1 1 3	"{'max_de pth': 5, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 260}"	0.77084 479	0.0216 30483	0.766634 475	0.02156 6465	0.7719150 4	0.021171 027	0.77257524 5	0.0216850 89
1 1 4	"{'max_de pth': 5, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 10}"	0.71029 8659	0.0301 50088	0.699511 833	0.02996 2707	0.7109437 44	0.031780 972	0.72267125 3	0.0337164 86
1 1 5	"{'max_de pth': 5, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 60}"	0.76108 5494	0.0281 21805	0.755896 131	0.02844 6676	0.7626454 3	0.027984 376	0.76410440 5	0.0269599 08
1 1 6	"{'max_de pth': 5, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 110}"	0.76303 7777	0.0241 36889	0.758287 663	0.02370 863	0.7645279 74	0.023367 679	0.76488778	0.0222670 36

1 1 7	"{'max_de pth': 5, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 160}"	0.77020 1785	0.0231 41751	0.766050 159	0.02355 9241	0.7711836 12	0.022997 44	0.77170919 3	0.0249191 75
1 1 8	"{'max_de pth': 5, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 210}"	0.76824 5273	0.0226 07428	0.763961 805	0.02281 4526	0.7691748 11	0.022245 466	0.76923285 8	0.0238291 25
1 1 9	"{'max_de pth': 5, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 260}"	0.77019 967	0.0236 21522	0.765902 019	0.02394 382	0.7712401 04	0.023549 34	0.77058668	0.0231057 24
1 2 0	"{'max_de pth': 6, 'max_sam ples': 0.1, 'n_estima tors': 10}"	0.66405 9393	0.0275 50247	0.649601 524	0.03172 5717	0.6617382 84	0.027403 557	0.66050318 8	0.0330014 8
1 2 1	"{'max_de pth': 6, 'max_sam ples': 0.1, 'n_estima tors': 60}"	0.73634 037	0.0228 79077	0.730552 577	0.02132 4549	0.7367901 59	0.022711 483	0.74184391	0.0220588 57
1 2 2	"{'max_de pth': 6, 'max_sam ples': 0.1, 'n_estima tors': 110}"	0.75521 1726	0.0241 10836	0.749912 427	0.02251 3812	0.7563514	0.022811 85	0.75512458 1	0.0224824 49
1 2 3	"{'max_de pth': 6, 'max_sam ples': 0.1, 'n_estima tors': 160}"	0.76042 7683	0.0278 87093	0.754721 594	0.02661 0336	0.7612129 43	0.027137 265	0.76084318 5	0.0263211 98

1 2 4	"{'max_depth': 6, 'max_samples': 0.1, 'n_estimators': 210}"	0.76563 5179	0.0199 49644	0.760826 156	0.01770 5288	0.7663474 57	0.019204 055	0.76643062 7	0.0175844 2
1 2 5	"{'max_depth': 6, 'max_samples': 0.1, 'n_estimators': 260}"	0.76303 3546	0.0228 32557	0.757974 721	0.02087 8056	0.7640047 9	0.022081 171	0.76200436 5	0.0215397 21
1 2 6	"{'max_depth': 6, 'max_samples': 0.300000 00000000 004, 'n_estimators': 10}"	0.70835 4837	0.0283 41798	0.697689 01	0.03278 5886	0.7086899 74	0.027231 409	0.70737721 9	0.0288403 45
1 2 7	"{'max_depth': 6, 'max_samples': 0.300000 00000000 004, 'n_estimators': 60}"	0.77019 544	0.0211 12417	0.765597 377	0.02094 7886	0.7707523 72	0.020889 465	0.77307770 8	0.0180760 99
1 2 8	"{'max_depth': 6, 'max_samples': 0.300000 00000000 004, 'n_estimators': 110}"	0.76954 1859	0.0265 54024	0.765427 988	0.02534 522	0.7703378 44	0.026021 388	0.77129418 2	0.0245698 82
1 2 9	"{'max_depth': 6, 'max_samples': 0.300000 00000000 004, 'n_estimators': 160}"	0.77865 1804	0.0245 77595	0.774785 326	0.02344 2956	0.7792427 55	0.024108 782	0.78187185	0.0233073 89
1 3 0	"{'max_depth': 6, 'max_samples': 0.300000 00000000	0.77931 3846	0.0312 0249	0.775458 701	0.03081 8349	0.7797230 19	0.030531 199	0.78158347 9	0.0318248 08

	004, 'n_estima tors': 210}"								
1 3 1	"{'max_de pth': 6, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 260}"	0.78126 6128	0.0287 32845	0.777548 62	0.02810 0295	0.7823324 29	0.028114 682	0.78229269 6	0.0290446 29
1 3 2	"{'max_de pth': 6, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 10}"	0.70639 1979	0.0285 18362	0.696066 722	0.02930 53	0.7083213 98	0.028095 361	0.70673217 1	0.0290409 71
1 3 3	"{'max_de pth': 6, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 60}"	0.77995 8966	0.0224 11048	0.777214 023	0.02201 7724	0.7810203 11	0.022281 019	0.78216265 6	0.0218552 38
1 3 4	"{'max_de pth': 6, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 110}"	0.78192 1824	0.0278 32537	0.778838 742	0.02715 7748	0.7824971 12	0.027526 164	0.78430482	0.0273499 4
1 3 5	"{'max_de pth': 6, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 160}"	0.78582 4273	0.0237 09503	0.782864 589	0.02366 6504	0.7863598	0.023890 477	0.78800151 7	0.0222851 52
1 3 6	"{'max_de pth': 6, 'max_sam ples': 0.500000 00000000	0.78712 509	0.0202 71075	0.784165 714	0.02030 0195	0.7880562 64	0.020408 015	0.78948704 8	0.0204188 92

	01, 'n_estima tors': 210}"								
1 3 7	"{'max_de pth': 6, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 260}"	0.78517 0692	0.0215 44062	0.782290 293	0.02121 6224	0.7862955 82	0.021474 671	0.78754922 9	0.0198992 51
1 3 8	"{'max_de pth': 6, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 10}"	0.74869 0723	0.0097 04855	0.742249 094	0.00958 3331	0.7499723 57	0.009289 315	0.74782699 1	0.0103440 62
1 3 9	"{'max_de pth': 6, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 60}"	0.77280 1303	0.0183 82998	0.769247 422	0.01822 927	0.7738205 92	0.018237 704	0.77539069 9	0.0171842 87
1 4 0	"{'max_de pth': 6, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 110}"	0.77279 9188	0.0223 68577	0.769450 749	0.02158 3833	0.7736804 52	0.021383 895	0.77483277 1	0.0215355 57
1 4 1	"{'max_de pth': 6, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 160}"	0.78191 3364	0.0200 37249	0.778557 832	0.01919 0927	0.7824144 85	0.019203 425	0.78508516 9	0.0193146 7
1 4 2	"{'max_de pth': 6, 'max_sam ples': 0.700000 00000000	0.78190 7018	0.0230 63991	0.778920 654	0.02273 9948	0.7826328 17	0.022749 371	0.78373451 7	0.0222248 33



	01, 'n_estima tors': 210}"								
1 4 3	"{'max_de pth': 6, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 260}"	0.78061 0432	0.0196 84101	0.777425 868	0.01963 2523	0.7812375 7	0.019142 19	0.78154647 8	0.0190365 1
1 4 4	"{'max_de pth': 6, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 10}"	0.74349 3803	0.0186 37968	0.738577 743	0.01681 5562	0.7451550 32	0.018732 724	0.74211198 9	0.0168011 35
1 4 5	"{'max_de pth': 6, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 60}"	0.78321 841	0.0232 93448	0.780803 562	0.02256 6047	0.7845656 98	0.023588 372	0.785559	0.0232852 01
1 4 6	"{'max_de pth': 6, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 110}"	0.78126 1898	0.0233 119	0.778728 848	0.02276 766	0.7824872 67	0.023280 173	0.78327928 4	0.0227055 03
1 4 7	"{'max_de pth': 6, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 160}"	0.78386 9876	0.0249 60333	0.781333 676	0.02454 7017	0.7851274 14	0.025198 594	0.78709947 9	0.0234821 77
1 4 8	"{'max_de pth': 6, 'max_sam ples': 0.900000 00000000	0.78712 509	0.0222 66523	0.784352 718	0.02215 797	0.7884044 84	0.022114 206	0.78936547 8	0.0222103 85

	01, 'n_estima tors': 210}"								
1 4 9	"{'max_de pth': 6, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 260}"	0.78712 2975	0.0205 0607	0.784153 864	0.02021 0703	0.7880562 64	0.020716 927	0.78892126 2	0.0203355 88
1 5 0	"{'max_de pth': 7, 'max_sam ples': 0.1, 'n_estima tors': 10}"	0.67645 4165	0.0376 98728	0.666246 214	0.04063 473	0.6754268 33	0.037308 667	0.67421893 6	0.0389158 13
1 5 1	"{'max_de pth': 7, 'max_sam ples': 0.1, 'n_estima tors': 60}"	0.75586 9538	0.0222 57669	0.750544 827	0.02207 8697	0.7571043 89	0.020803 669	0.75284923 6	0.0223306 46
1 5 2	"{'max_de pth': 7, 'max_sam ples': 0.1, 'n_estima tors': 110}"	0.76042 3453	0.0172 08442	0.755853 401	0.01524 772	0.7611228 6	0.015912 024	0.75836631	0.0170217 18
1 5 3	"{'max_de pth': 7, 'max_sam ples': 0.1, 'n_estima tors': 160}"	0.77149 2026	0.0179 01695	0.766774 201	0.01680 8988	0.7721734 55	0.016798 235	0.76918686 9	0.0175795 95
1 5 4	"{'max_de pth': 7, 'max_sam ples': 0.1, 'n_estima tors': 210}"	0.77084 056	0.0153 83169	0.766184 904	0.01389 4282	0.7711536 34	0.014925 339	0.76905407 8	0.0156686 19
1 5 5	"{'max_de pth': 7, 'max_sam ples': 0.1, 'n_estima tors': 260}"	0.76693 8111	0.0171 46674	0.762132 617	0.01570 3921	0.7676027 53	0.015969 082	0.76370602	0.0163451 11
1 5 6	"{'max_de pth': 7, 'max_sam ples':	0.74349 8033	0.0240 51111	0.737734 69	0.02585 341	0.7444092 64	0.025116 565	0.73949486	0.0236651 09

	0.300000 00000000 004, 'n_estima tors': 10}"								
1 5 7	"{'max_de pth': 7, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 60}"	0.79231 9895	0.0198 84607	0.789388 794	0.01994 3785	0.7926689 02	0.019891 191	0.79236844 6	0.0195809 41
1 5 8	"{'max_de pth': 7, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 110}"	0.78907 5257	0.0191 03843	0.786194 633	0.01815 8543	0.7894657 02	0.018425 636	0.78937627 1	0.0182460 98
1 5 9	"{'max_de pth': 7, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 160}"	0.79622 869	0.0159 72385	0.793040 978	0.01506 1324	0.7962428 98	0.015761 99	0.79831252 1	0.0157119 85
1 6 0	"{'max_de pth': 7, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 210}"	0.79688 0156	0.0138 30285	0.793819 583	0.01278 4662	0.7970048 74	0.013412 833	0.79838257	0.0125064 33
1 6 1	"{'max_de pth': 7, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 260}"	0.79166 8429	0.0146 84273	0.787840 106	0.01414 663	0.7920393 48	0.014187 916	0.79155653	0.0136843 13
1 6 2	"{'max_de pth': 7, 'max_sam ples':	0.75195 4397	0.0105 49925	0.747956 308	0.01031 2455	0.7523871 15	0.010573 583	0.75193490 8	0.0109407 84

	0.500000 00000000 01, 'n_estima tors': 10}"								
1 6 3	"{'max_de pth': 7, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 60}"	0.80015 6521	0.0276 8506	0.797438 911	0.02722 5856	0.7995417 99	0.027785 655	0.80206471 7	0.0254620 87
1 6 4	"{'max_de pth': 7, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 110}"	0.80079 9526	0.0225 12896	0.798611 196	0.02179 8315	0.8008161 8	0.022131 924	0.80220406 4	0.0210968 65
1 6 5	"{'max_de pth': 7, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 160}"	0.79884 9359	0.0234 01812	0.796120 199	0.02281 471	0.7986230 77	0.023089 748	0.80081331 8	0.0234762 15
1 6 6	"{'max_de pth': 7, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 210}"	0.80405 2625	0.0223 49875	0.801659 235	0.02191 3279	0.8037993 09	0.022324 935	0.80654133 2	0.0210049 75
1 6 7	"{'max_de pth': 7, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 260}"	0.80339 6929	0.0200 17962	0.800394 464	0.01895 1719	0.8032096 02	0.019757 52	0.80499686 6	0.0183958 75
1 6 8	"{'max_de pth': 7, 'max_sam ples':	0.75653 3694	0.0349 79765	0.752459 782	0.03367 3305	0.7582297 36	0.034494 425	0.75738025	0.0329272 28

	0.700000 00000000 01, 'n_estima tors': 10}"								
1 6 9	"{'max_de pth': 7, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 60}"	0.78386 5646	0.0283 45334	0.781369 149	0.02848 4728	0.7850590 25	0.027964 96	0.78607249 3	0.0291919 52
1 7 0	"{'max_de pth': 7, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 110}"	0.78972 6723	0.0246 47968	0.787440 398	0.02357 7684	0.7906298 62	0.024173 307	0.79062916 9	0.0235376 71
1 7 1	"{'max_de pth': 7, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 160}"	0.79363 5518	0.0204 84358	0.791181 149	0.02001 6365	0.7941282 88	0.019951 882	0.79544156 5	0.0206544 69
1 7 2	"{'max_de pth': 7, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 210}"	0.79428 2753	0.0166 24601	0.791382 803	0.01615 8235	0.7947819 95	0.015973 318	0.79543040 9	0.0156104 17
1 7 3	"{'max_de pth': 7, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 260}"	0.79753 3737	0.0152 23138	0.794651 381	0.01445 81	0.7976939 32	0.014941 895	0.79831024	0.0131811 52
1 7 4	"{'max_de pth': 7, 'max_sam ples':	0.76431 9557	0.0254 77559	0.761898	0.02576 1969	0.7645106 83	0.026792 697	0.76615893 6	0.0261868 03

	0.900000 00000000 01, 'n_estima tors': 10}"								
1 7 5	"{'max_de pth': 7, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 60}"	0.79687 381	0.0131 423	0.794762 919	0.01182 5486	0.7973444 16	0.013507 418	0.79991798	0.0074445 03
1 7 6	"{'max_de pth': 7, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 110}"	0.80274 3348	0.0161 80664	0.800334 652	0.01536 1103	0.8030945 95	0.015910 759	0.80458953 3	0.0155046 25
1 7 7	"{'max_de pth': 7, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 160}"	0.80469 563	0.0159 82317	0.802078 586	0.01581 7388	0.8047751 89	0.016342 564	0.80627154 3	0.0147669 51
1 7 8	"{'max_de pth': 7, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 210}"	0.80534 9211	0.0175 19515	0.802288 145	0.01712 4124	0.8052129 08	0.017715 107	0.80651060 9	0.0160775 41
1 7 9	"{'max_de pth': 7, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 260}"	0.80599 8562	0.0171 99559	0.802935 29	0.01703 865	0.8059401 81	0.017377 228	0.80721381 3	0.0162794 52
1 8 0	"{'max_de pth': 8, 'max_sam ples': 0.1,	0.67840 2217	0.0270 65215	0.665562 019	0.02688 5744	0.6779501 47	0.025858 022	0.66925263 9	0.0302921 88

	'n_estima tors': 10}"								
1 8 1	"{'max_de pth': 8, 'max_sam ples': 0.1, 'n_estima tors': 60}"	0.75520 9611	0.0159 8774	0.750578 105	0.01537 3372	0.7556739 18	0.015294 963	0.75244818 8	0.0156853 19
1 8 2	"{'max_de pth': 8, 'max_sam ples': 0.1, 'n_estima tors': 110}"	0.77019 1209	0.0251 09109	0.766031 4	0.02376 0992	0.7703824 26	0.024558 404	0.76935737 9	0.0224371 46
1 8 3	"{'max_de pth': 8, 'max_sam ples': 0.1, 'n_estima tors': 160}"	0.77409 7889	0.0182 54752	0.768904 345	0.01685 8585	0.7743797 44	0.017875 593	0.77133487 7	0.0175364 87
1 8 4	"{'max_de pth': 8, 'max_sam ples': 0.1, 'n_estima tors': 210}"	0.77669 3177	0.0191 63558	0.772034 4	0.01802 0966	0.7763526 51	0.019051 999	0.77563657 7	0.0183417 64
1 8 5	"{'max_de pth': 8, 'max_sam ples': 0.1, 'n_estima tors': 260}"	0.77539 0245	0.0159 60257	0.770745 258	0.01430 0993	0.7757472 37	0.015670 264	0.77391737 8	0.0146803 65
1 8 6	"{'max_de pth': 8, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 10}"	0.73893 9887	0.0158 76716	0.735916 423	0.01603 6015	0.7397710 74	0.015146 204	0.73646437 5	0.0182009 32
1 8 7	"{'max_de pth': 8, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 60}"	0.78645 8818	0.0228 04342	0.783565 095	0.02198 6576	0.7865405 17	0.021636 839	0.78600767 4	0.0213504 91
1 8 8	"{'max_de pth': 8, 'max_sam ples':	0.79167 0544	0.0193 90253	0.788604 468	0.01847 2677	0.7915654 34	0.018702 528	0.79196898 4	0.0177641 73

	0.300000 00000000 004, 'n_estima tors': 110}"								
1 8 9	"{'max_de pth': 8, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 160}"	0.79948 8134	0.0186 18194	0.796179 117	0.01827 8132	0.7990578 45	0.018591 567	0.79949295 6	0.0188878 22
1 9 0	"{'max_de pth': 8, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 210}"	0.79753 3737	0.0239 89876	0.794070 612	0.02383 477	0.7970321 3	0.023755 752	0.79757686 9	0.0251644 95
1 9 1	"{'max_de pth': 8, 'max_sam ples': 0.300000 00000000 004, 'n_estima tors': 260}"	0.79753 3737	0.0219 57788	0.794051 953	0.02167 4919	0.7972336 21	0.022002 042	0.79722921 7	0.0218266 45
1 9 2	"{'max_de pth': 8, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 10}"	0.76433 4363	0.0221 12199	0.759503 967	0.02087 9849	0.7657675	0.020782 182	0.76076502 8	0.0224325 67
1 9 3	"{'max_de pth': 8, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 60}"	0.79298 1937	0.0215 24623	0.790550 285	0.02096 1106	0.7934239 86	0.021337 746	0.79310425 4	0.0204275 28
1 9 4	"{'max_de pth': 8, 'max_sam ples':	0.80014 5945	0.0218 91333	0.797377 128	0.02178 5463	0.8003445 89	0.021826 37	0.80002011 7	0.0206108 89




	0.500000 00000000 01, 'n_estima tors': 110}"								
1 9 5	"{'max_de pth': 8, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 160}"	0.80274 3348	0.0148 1125	0.799581 415	0.01437 3694	0.8027016 37	0.014981 396	0.80222273 5	0.0125236 72
1 9 6	"{'max_de pth': 8, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 210}"	0.80534 4981	0.0168 32821	0.802246 715	0.01661 8357	0.8048564 35	0.017198 086	0.80623004	0.0150817 68
1 9 7	"{'max_de pth': 8, 'max_sam ples': 0.500000 00000000 01, 'n_estima tors': 260}"	0.80729 5148	0.0156 97378	0.804531 642	0.01513 7858	0.8071540 7	0.016273 345	0.80804156 3	0.0126264 95
1 9 8	"{'max_de pth': 8, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 10}"	0.76368 0782	0.0176 64817	0.759925 01	0.01793 424	0.7646945 16	0.017516 87	0.75969620 2	0.0181890 97
1 9 9	"{'max_de pth': 8, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 60}"	0.79754 4312	0.0185 8593	0.795651 469	0.01813 445	0.7984735 07	0.017935 021	0.7972289	0.0171534 87
2 0 0	"{'max_de pth': 8, 'max_sam ples':	0.79884 7244	0.0188 0249	0.796733 258	0.01809 5229	0.7992849 91	0.018781 517	0.79966252 3	0.0169877 5

	0.700000 00000000 01, 'n_estima tors': 110}"								
2 0 1	"{'max_de pth': 8, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 160}"	0.80079 7411	0.0197 24753	0.798151 377	0.01931 1779	0.8010892 37	0.019288 101	0.80135975 1	0.0184025 92
2 0 2	"{'max_de pth': 8, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 210}"	0.80470 8321	0.0239 14025	0.802585 713	0.02359 8555	0.8049892 39	0.023826 845	0.80566854 8	0.0223275 26
2 0 3	"{'max_de pth': 8, 'max_sam ples': 0.700000 00000000 01, 'n_estima tors': 260}"	0.80600 7022	0.0198 41915	0.803978 146	0.01924 2776	0.8063001 34	0.019931 377	0.80674824 8	0.0184090 75
2 0 4	"{'max_de pth': 8, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 10}"	0.76759 5922	0.0184 71465	0.764359 98	0.01863 7765	0.7674187 31	0.018681 408	0.76584800 7	0.0202865 58
2 0 5	"{'max_de pth': 8, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 60}"	<b>0.81251 322</b>	0.0161 27878	<b>0.811035 181</b>	0.01624 2644	<b>0.8128250 99</b>	0.015696 488	<b>0.81459107 4</b>	0.0147293 22
2 0 6	"{'max_de pth': 8, 'max_sam ples':	0.80665 6373	0.0178 37043	0.804509 05	0.01739 1095	0.8068467 27	0.017619 85	0.80737460 8	0.0154704 76

	0.900000 00000000 01, 'n_estima tors': 110}"								
2 0 7	"{'max_de pth': 8, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 160}"	0.80926 0121	0.0207 07253	0.806986 273	0.02023 6216	0.8094936 02	0.020459 188	0.80868459 9	0.0187189 91
2 0 8	"{'max_de pth': 8, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 210}"	0.81056 5168	0.0188 25518	0.808003 581	0.01861 276	0.8104413 67	0.018555 354	0.81132597	0.0176070 62
2 0 9	"{'max_de pth': 8, 'max_sam ples': 0.900000 00000000 01, 'n_estima tors': 260}"	0.80665 4258	0.0159 84704	0.804168 614	0.01586 8993	0.8064683 19	0.015892 521	0.80759139 2	0.0144662 3

Se constată că performanța acestor RandomForests sunt dictate direct de adâncimea maximă a arborelui, numărul de arbori și de procentul de intrări care sunt folosite la antrenare (max\_samples). Un RandomForest la care fixăm numărul de estimatori și adâncimea maximă a arborelui are performanțe mai mari atunci când folosim mai multe date prin creșterea max\_samples.

Pentru configurația bolduită matricea de confuzie este



Observăm că în cazul acestui RandomForest, puterea de predicție pentru clasa de indice 6 (D6) a rămas puternică. Vedem o îmbunătățire în predicțiile claselor de indici 3,4 și 5.